

Protocolo Experimental

Comparacion de la calidad de requisitos funcionales elicitados por analistas humanos frente a los generados por un modelo de lenguaje (LLM) en un sistema agricola con IA
(Enfoque 1)

Escudero Plaza Maria del Rosario

Universidad Tecnica Estatal de Quevedo (UTEQ)

Proyecto Fin de Curso - Ingenieria de Requerimientos [20303]

Version 1.0 • Período 2026-2027 PPA

Resumen

El presente protocolo define el componente empirico del sistema **AgriMoreira**, un sistema de gestion agricola con inteligencia artificial para el apoyo a la toma de decisiones en cultivos de cacao y platanero verde. El estudio sigue el **Enfoque 1** de la guia: comparar la calidad de los requisitos funcionales (RF) elicitados por el equipo de analistas humanos con los generados por un modelo de lenguaje de gran escala (LLM) a partir del mismo material fuente (transcripcion anonimizada de una entrevista de campo). Se aplica un diseno cuasi-experimental apareado: ambos conjuntos de RF (humano y LLM), de un minimo de 25 requisitos cada uno, se evaluan a ciegas por evaluadores expertos independientes en cinco dimensiones de calidad (completitud, ausencia de ambigüedad, verificabilidad, correccion respecto de la fuente y consistencia interna). El acuerdo inter-evaluador se mide con los coeficientes kappa de Cohen y de Fleiss, y las puntuaciones medias se comparan con prueba t apareada o Wilcoxon segun normalidad, con tamano del efecto y calculo de potencia estadistica previa. El protocolo se registra de forma previa en el Open Science Framework (OSF) [1].

Índice

1. Informacion general del proyecto	3
2. Preguntas de investigacion (formato PICOC)	3
2.1. Preguntas de investigacion	3
2.2. Aplicacion del marco PICOC	3
3. Hipotesis	4
4. Variables del estudio	4
4.1. Variables independientes	4

4.2. Variables dependientes	4
4.3. Variables de control	4
5. Diseño del estudio	4
6. Participantes (evaluadores expertos) y reclutamiento	5
7. Instrumentos	5
8. Plan de analisis estadistico	6
8.1. Analisis descriptivo	6
8.2. Pruebas de hipotesis	6
8.3. Acuerdo inter-evaluador	6
8.4. Calculo de potencia previo	6
8.5. Reproducibilidad	6
9. Consideraciones eticas	6
10.Registro previo (preregistro)	7
11.Cronograma	7
12.Amenazas a la validez	7

1. Informacion general del proyecto

Elemento	Descripcion
Nombre del sistema	AgriMoreira: Sistema de Gestion Agricola con IA para cultivos de verde y cacao
Dominio	Agroindustria (produccion de cacao y platanero verde, Manabi, Ecuador)
Organizacion cliente	Agricola Moreira (seudonimo declarado en el protocolo de anonimizacion)
Enfoque empirico	Enfoque 1: Calidad de RF humanos vs. LLM
Asignatura	Ingenieria de Requerimientos [20303]
Integrante responsable	Escudero Plaza Maria del Rosario
Docente supervisor	Mgs. Gleiston Ciceron Guerrero Ulloa

2. Preguntas de investigacion (formato PICOC)

Las preguntas de investigacion se formulan siguiendo el marco PICOC (poblacion, intervencion, comparacion, resultado, contexto) [2].

2.1. Preguntas de investigacion

1. **RQ1.** *¿En que dimensiones de calidad los requisitos funcionales (RF) elicitados por el equipo humano difieren de los generados por un LLM a partir del mismo material fuente?*
2. **RQ2.** *¿Cual es el nivel de acuerdo inter-evaluador (kappa de Cohen y de Fleiss) entre los evaluadores expertos al puntuar ambos conjuntos de RF?*
3. **RQ3.** *¿Cual es la magnitud del efecto (Cohen d o Cliff delta) de la diferencia de calidad entre RF humanos y LLM en cada dimension?*

2.2. Aplicacion del marco PICOC

Componente	Descripcion
Poblacion (P)	Conjunto de requisitos funcionales del sistema AgriMoreira (≥ 25 RF humanos del ERS y ≥ 25 RF generados por LLM a partir del mismo material fuente).
Intervencion (I)	Evaluacion a ciegas de los RF con una rubrica de cinco dimensiones (completitud, ausencia de ambigüedad, verificabilidad, correccion respecto de la fuente y consistencia interna), puntuando 1–5.
Comparacion (C)	Conjunto de RF producidos por LLM (Conjunto A) frente al conjunto de RF elicitados por el equipo humano (Conjunto B).
Resultado (O)	Puntuacion media de calidad por dimension, acuerdo inter-evaluador (kappa de Cohen y de Fleiss), tamaño del efecto (d de Cohen o delta de Cliff).
Contexto (C)	Desarrollo de un sistema real de gestion agricola con IA en un dominio agroindustrial ecuatoriano, periodo 2026-2027.

3. Hipotesis

Al tratarse de una comparacion cuantitativa, se formulan hipotesis nulas y alternativas para cada dimension de calidad $j \in \{1, \dots, 5\}$:

H_{0j} : No existe diferencia estadisticamente significativa entre la puntuacion media de calidad de los RF humanos (Conjunto B) y la de los RF generados por LLM (Conjunto A) en la dimension j .
H_{1j} : Existe una diferencia estadisticamente significativa entre ambas puntuaciones medias en la dimension j .

Nivel de significancia fijado en $\alpha = 0,05$.

4. Variables del estudio

4.1. Variables independientes

- Origen del conjunto de requisitos: Conjunto A (LLM) vs. Conjunto B (equipo humano).

4.2. Variables dependientes

- Puntuacion de calidad de cada RF en cada dimension (escala 1–5): completitud, ausencia de ambigüedad, verificabilidad, correccion respecto de la fuente y consistencia interna.
- Acuerdo inter-evaluador: kappa de Cohen [3] entre pares de evaluadores y kappa de Fleiss [4] para el conjunto completo.

4.3. Variables de control

- Material fuente unico: la misma transcripcion anonimizada de entrevista para ambos conjuntos.
- Rubrica de evaluacion identica para ambos conjuntos y todos los evaluadores.
- Evaluadores independientes y ciegos (no saben cual conjunto es cual).
- Parametros del LLM fijos: modelo, temperatura, top-p y semilla registrados en 06_Experimento/prompts_llm/.

5. Diseño del estudio

Cuasi-experimento apareado [5]:

1. Selecccion del material fuente unico: la transcripcion completa de la entrevista al administrador (Entr-01, evidencia EV-01 en la matriz de trazabilidad, archivo 02_Evidencias/Trans anonimizada.

2. Ejecucion del LLM con la consigna exacta: “*A partir del siguiente material fuente, redacta requisitos funcionales del sistema descrito, con los ocho atributos de la plantilla del silabo*”. Se registra la consigna completa, el modelo, la temperatura, el top-p, la semilla y la fecha y hora de la consulta.
3. Conjunto A (RF generados por el LLM) y Conjunto B (RF elicitados por el equipo humano, tomados del ERS). Cada conjunto debe tener un minimo de 25 requisitos individuales para permitir el analisis estadistico apareado [6].
4. Evaluacion a ciegas: tres o mas evaluadores expertos independientes (cinco es el numero recomendado) puntuan cada RF de 1 a 5 en las cinco dimensiones, sin saber cual conjunto es humano y cual es LLM.

6. Participantes (evaluadores expertos) y reclutamiento

- **Evaluadores expertos:** un minimo de 3 y un maximo de 5 personas expertas independientes (por ejemplo, tres estudiantes de otro paralelo o tres docentes del area de Ingenieria de Requerimientos).
- **Criterios de inclusion:** conocimientos de ingenieria de requisitos y/o de especificacion de software; no haber participado en la elicitation de los RF del equipo.
- **Criterios de exclusion:** miembros del equipo de desarrollo de AgriMoreira y personas que hayan redactado alguno de los conjuntos de RF.
- **Proceso de consentimiento:** consentimiento informado firmado, conforme a la Ley Organica de Proteccion de Datos Personales del Ecuador [7]; autorizacion explicita para el uso de datos anonimizados en publicaciones cientificas revisadas por pares y para el deposito del conjunto de datos anonimizado en Zenodo con licencia CC BY 4.0.

7. Instrumentos

Los instrumentos completos se encuentran en la carpeta 06_Experimento/instrumentos/ y los prompts en 06_Experimento/prompts_llm/:

1. **Material fuente unico:** transcripcion anonimizada de la entrevista al administrador (Entr-01, EV-01), sin nombres propios.
2. **Consigna exacta del LLM** con modelo, temperatura, top-p, semilla, fecha y hora de la consulta (archivo Markdown por experimento).
3. **Rubrica de evaluacion experta:** cada RF se puntua de 1 a 5 en cinco dimensiones (completitud, ausencia de ambigüedad, verificabilidad, correccion respecto de la fuente y consistencia interna).
4. **Hoja de evaluacion a ciegas:** plantilla para que los evaluadores registren sus puntuaciones por RF y por dimension.

5. **Plantilla de consentimiento actualizado:** disponible en la carpeta etica del repositorio (08_Etica/).

8. Plan de analisis estadistico

8.1. Analisis descriptivo

Se calculan la media, la desviacion estandar y las distribuciones de frecuencias de las puntuaciones por conjunto (A y B), por dimension y por evaluador.

8.2. Pruebas de hipotesis

1. Prueba de normalidad de **Shapiro-Wilk** sobre las diferencias apareadas.
2. Si los datos son normales: prueba **t de Student para muestras apareadas**.
3. Si no son normales: prueba **de Wilcoxon** para muestras apareadas.
4. Tamano del efecto: coeficiente **d de Cohen** (datos normales) o **delta de Cliff** (datos no normales).
5. Correccion por comparaciones multiples (por ejemplo, Bonferroni) cuando se compare mas de una dimension simultaneamente.

8.3. Acuerdo inter-evaluador

- kappa de Cohen [3] para la concordancia entre cada par de evaluadores.
- kappa de Fleiss [4] para la concordancia del conjunto completo de evaluadores.

8.4. Calculo de potencia previo

Potencia estadistica fijada en $1 - \beta = 0,80$, $\alpha = 0,05$, tamano de efecto medio de Cohen $d = 0,5$, conforme a la lista de verificacion de encuestas de Moller, Petersen y Mendes [8]. El calculo se realiza antes de la ejecucion del experimento.

8.5. Reproducibilidad

Todos los calculos se ejecutan con los scripts de Python versionados en 06_Experimento/scripts_analisis/. a partir de los datos crudos en 06_Experimento/resultados/. Ninguna tabla ni figura del manuscrito se produce manualmente.

9. Consideraciones eticas

- Los evaluadores y participantes firman consentimiento informado antes de cualquier recoleccion de datos.
- No se publican datos identificables: la firma, la cedula, el rostro y la voz permanecen en zona restringida.

- El proyecto es de riesgo minimo operativo (Categoria C del paquete etico).
- La adenda de la segunda ronda se encuentra en 08_Etica/Adenda_Segunda_Ronda.pdf y tiene fecha anterior al primer consentimiento de la segunda ronda.

10. Registro previo (preregistro)

El protocolo se registra en el Open Science Framework (<https://osf.io>) con fecha anterior a la ejecucion del experimento, siguiendo la revolucion del preregistro documentada por [1]. El comprobante de registro con URL persistente se almacena como 06_Experimento/osf_registration.pdf.

11. Cronograma

Actividad	Semana
Registro del protocolo en OSF	Semana 11
Ejecucion del LLM (Conjunto A) y conformacion de los conjuntos	Semana 12
Evaluacion a ciegas por los evaluadores expertos	Semana 13
Analisis estadistico y figuras	Semana 14
Redaccion de resultados del manuscrito	Semana 15–16

12. Amenazas a la validez

Validez interna: se controla que ambos conjuntos se evaluen con la misma rubrica y los mismos evaluadores a ciegas. Limitacion: la seleccion del material fuente unico puede influir en la calidad de los RF de ambos conjuntos.

Validez externa: el estudio se limita a un sistema agroindustrial ecuatoriano y a un solo material fuente; los resultados no son generalizables sin estudios de replicacion.

Validez de constructo: la calidad de requisitos se operacionaliza en cinco dimensiones validadas en la literatura [6]; se triangula con el acuerdo inter-evaluador.

Validez de conclusion: se reportan el estadistico, los grados de libertad, el valor p y el tamano del efecto en cada afirmacion cuantitativa.

Referencias

- [1] Brian A. Nosek, Charles R. Ebersole, Alexander C. DeHaven, and David T. Mellor. The preregistration revolution. *Proceedings of the National Academy of Sciences*, 115(11):2600–2606, 2018.
- [2] Barbara Kitchenham and Stuart Charters. Guidelines for performing systematic literature reviews in software engineering. Technical Report EBSE 2007-001, Keele University and Durham University, 2007.
- [3] Jacob Cohen. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46, 1960.

- [4] Joseph L. Fleiss. Measuring nominal scale agreement among many raters. *Psychological Bulletin*, 76(5):378–382, 1971.
- [5] Claes Wohlin, Per Runeson, Martin Höst, Magnus C. Ohlsson, Björn Regnell, and Anders Wesslén. *Experimentation in Software Engineering*. Springer, Berlin, Heidelberg, 2012.
- [6] Lloyd Montgomery, Davide Fucci, Abir Bouraffa, Lisa Scholz, and Walid Maalej. Empirical research on requirements quality: a systematic mapping study. *Requirements Engineering*, 27(2):183–209, 2022.
- [7] Asamblea Nacional del Ecuador. Ley organica de proteccion de datos personales. 2021. Registro Oficial Suplemento No. 459.
- [8] Jorge S. Molléri, Kai Petersen, and Emilia Mendes. An empirically evaluated checklist for surveys in software engineering. *Information and Software Technology*, 119:106240, 2020.