

Comparacion de la calidad de requisitos funcionales elicitados por analistas humanos frente a los generados por un modelo de lenguaje (LLM) en un sistema agricola con IA

Grupo ACERS

Universidad Tecnica Estatal de Quevedo (UTEQ)

Proyecto Fin de Curso - Ingenieria de Requerimientos [20303]

Version 1.0 (borrador, Entrega 3) • Semestre 2026-2027

Resumen

Los modelos de lenguaje de gran escala (LLM) se estan integrando cada vez mas en la fase de elicitation de requisitos de la ingenieria de software [?, ?]. Sin embargo, la evidencia empirica sobre la calidad de los requisitos funcionales (RF) generados por un LLM frente a los elicitados por analistas humanos a partir de un mismo material fuente es todavia limitada, especialmente en dominios agroindustriales de paises en desarrollo. En este trabajo se realiza un cuasi-experimento apareado en el dominio agroindustrial ecuatoriano: un equipo humano y un LLM (gpt-4o-2024-08-06, temperatura 0.0, top-p 1.0, semilla 42) producen sendos conjuntos de requisitos funcionales (minimo 25 cada uno) a partir de la misma transcripcion anonimizada de una entrevista de campo del sistema **AgriMoreira**. Tres o mas evaluadores expertos independientes puntuan a ciegas ambos conjuntos en cinco dimensiones de calidad (completitud, ausencia de ambigüedad, verificabilidad, correccion respecto de la fuente y consistencia interna). El acuerdo inter-evaluador se mide con kappa de Cohen [?] y de Fleiss [?]; las medias se comparan con prueba t pareada o Wilcoxon segun normalidad, reportando el tamano del efecto (d de Cohen o delta de Cliff) y el calculo de potencia previo ($\alpha = 0.05$, $1 - \beta = 0.80$) [?]. El protocolo se registra de forma previa en el OSF [?] y el conjunto de datos anonimizado se depositara en Zenodo bajo licencia CC BY 4.0 [?].

Palabras clave: ingenieria de requisitos, elicitation, modelos de lenguaje, calidad de requisitos, experimento empirico.

1. Introduccion

El sistema **AgriMoreira** es una plataforma de gestion agricola con inteligencia artificial para cultivos de platanero verde y cacao en Manabi, Ecuador, desarrollada como proyecto academico de la asignatura de Ingenieria de Requerimientos. La finca real de la organizacion cliente (Agricola Moreira, seudonimo declarado en el protocolo de anonimizacion) registra hoy su produccion, inventario y actividades de forma manual en cuadernos, segun las entrevistas y encuestas de la primera y segunda ronda de campo. En este dominio, la calidad de los requisitos funcionales que sustentan el sistema es determinante: un requisito ambiguo o incompleto se traduce directamente en perdida de informacion y en decisiones agronomicas incorrectas. Por ello, estudiar la ingenieria de requerimientos en este contexto no es un ejercicio academico abstracto, sino una necesidad operativa real de una cadena de valor agropecuaria.

El gap de conocimiento que este trabajo aborda es doble. Por un lado, la revision sistematica de Cheng et al. [?] indica que la fase de gestion de requisitos recibe atencion insuficiente frente a otras actividades del proceso, y que las guias de uso de LLM en ingenieria de requisitos, como la de Vogelsang y Fischbach [?], aun no han sido validadas en contextos latinoamericanos ni en dominios agropecuarios. Por otro lado, Arora et al. [?] senalan que, aunque los LLM pueden acelerar la elicitation, se carece de evidencia empirica controlada que compare la calidad resultante frente a la elicitation humana clasica sobre una misma fuente.

Las contribuciones de este trabajo son las siguientes:

1. Una evidencia empirica adicional que complementa el mapeo sistematico de Montgomery et al. [?] y las guias de [?] sobre el uso de LLM en la elicitation de requisitos, medida en cinco dimensiones de calidad con evaluadores a ciegas.
2. Un protocolo reproducible y preregistrado (OSF) para comparar RF humanos frente a LLM, con instrumentos, consignas, parametros del modelo y scripts de analisis publicados en el repositorio.
3. Un conjunto de datos anonimizado depositado en Zenodo con licencia CC BY 4.0, siguiendo los principios FAIR [?] y las practicas de citacion de software [?, ?].

El resto del manuscrito se organiza asi: la Seccion 2 presenta el trabajo relacionado; la Seccion 3 describe la metodologia del cuasi-experimento (Enfoque 1); las secciones de resultados, discusion y conclusiones se completaran en la Entrega 4 (2B) con los datos analizados.

2. Trabajo relacionado

Para delimitar el estado del arte se ejecuto una busqueda sistematica de literatura con la cadena de tres terminos: (requirements engineering.^{OR} requisitos de software") AND ("large language model.^{OR} ChatGPT.^{OR} Claude") AND (.^{elicit}ation.^{OR} "quality"), en las bases de datos Scopus y Google Scholar, limitando el periodo a los ultimos tres anos. Los criterios de inclusion fueron: estudios revisados por pares con datos empiricos publicados en conferencias o revistas de ingenieria de requisitos. Los criterios de exclusion fueron: editoriales, presentaciones breves de menos de cuatro paginas y estudios sin datos.

El Cuadro 1 resume los estudios mas relevantes.

Referencia	Ano	Tipo de estudio	Poblacion	Intervencion	Diferencia con nuestro trabajo
Cheng et al. [?]	2026	Revision sistematica	Literatura de IA generativa en RE	Analisis de estudios sobre generacion de requisitos	Es una revision; no mide calidad en un experimento controlado
Arora et al. [?]	2024	Vision/posicion	Comunidad de RE	Evaluacion cualitativa del rol de los LLM	No aporta comparacion cuantitativa apareada
Vogelsang y Fischbach [?]	2024	Guia	Practicantes de RE	Directrices de uso de LLM en tareas de PLN	No valida la guia en dominio agroindustrial latinoamericano
Montgomery et al. [?]	2022	Mapeo sistematico	Estudios de calidad de requisitos	Clasificacion de operacionalizaciones de calidad	No compara humanos frente a LLM sobre una misma fuente

Tabla 1: Cuadro comparativo del trabajo relacionado.

El nicho concreto que ocupa nuestro estudio es la comparacion controlada y cuantitativa, sobre un unico material fuente, entre la calidad de los RF producidos por un equipo humano y la producida por un LLM con parametros fijos, en un dominio agroindustrial real de Ecuador. Los estudios previos documentan el potencial de los LLM o clasifican las dimensiones de calidad, pero no ofrecen una evidencia apareada de cinco dimensiones con evaluadores a ciegas y analisis estadistico preregistrado en este contexto.

3. Metodologia

La metodologia sigue la plantilla de reporte de experimentos de Jedlitschka et al. [?] y la guia de Wohlin et al. [?] para cuasi-experimentos. El detalle completo esta en el protocolo experimental [?], registrado en el OSF con fecha anterior a la ejecucion.

3.1. Pregunta de investigacion (PICOC)

La pregunta principal es: *¿En que dimensiones de calidad los RF elicitados por un equipo humano difieren de los generados por un LLM a partir del mismo material fuente?*

Componente	Descripcion
Poblacion (P)	Conjuntos de RF del sistema AgriMoreira (≥ 25 RF humanos del ERS y ≥ 25 RF generados por LLM).
Intervencion (I)	Evaluacion a ciegas con rubrica de cinco dimensiones (escala 1-5).
Comparacion (C)	Conjunto A (LLM) frente a Conjunto B (equipo humano).
Resultado (O)	Puntuacion media de calidad por dimension, acuerdo inter-evaluador (kappa) y tamano del efecto.
Contexto (C)	Dominio agroindustrial ecuatoriano, periodo 2026-2027.

3.2. Hipotesis

Para cada dimension de calidad $j \in \{1, \dots, 5\}$:

$$H_{0j} : \mu_{B,j} = \mu_{A,j}, \quad H_{1j} : \mu_{B,j} \neq \mu_{A,j},$$

con $\alpha = 0,05$ y potencia $1 - \beta = 0,80$.

3.3. Variables

- **Independiente:** origen del conjunto de requisitos ($A = \text{LLM}$, $B = \text{humano}$).
- **Dependientes:** puntuacion de calidad por dimension (1-5) y acuerdo inter-evaluador (kappa de Cohen y de Fleiss).
- **De control:** material fuente unico (transcripcion anonimizada EV-01), rubrica identica, evaluadores ciegos e independientes, y parametros del LLM fijos (modelo, temperatura, top-p y semilla).

3.4. Diseno del estudio

Cuasi-experimento apareado [?]. El material fuente unico es la transcripcion anonimizada de la entrevista al administrador (Entr-01 = EV-01), disponible en 02_Evidencias/Transcripciones/. El LLM recibe exclusivamente esa transcripcion con la consigna de la guia y produce el Conjunto A; el Conjunto B lo conforman los RF del ERS (RF-01 a RF-16 segun la matriz de trazabilidad). Cada conjunto debe alcanzar un minimo de 25 requisitos individuales para el analisis estadistico apareado [?].

3.5. Participantes y reclutamiento

Se contratan de 3 a 5 evaluadores expertos independientes (por ejemplo, estudiantes de otro paralelo o docentes del area de Ingenieria de Requerimientos) con criterios de inclusion (conocimientos de RE, no haber participado en la elicitation) y exclusion (miembros del equipo). Cada evaluador firma consentimiento informado conforme a la Ley Organica de Proteccion de Datos Personales del Ecuador [?], con autorizacion para el uso de datos anonimizados en publicaciones y en el deposito en Zenodo con CC BY 4.0.

3.6. Instrumentos

1. Material fuente unico: transcripcion anonimizada de la entrevista EV-01.
2. Consigna exacta del LLM con parametros registrados en `06_Experimento/prompts_llm/experimento_enf`.
3. Rubrica de evaluacion experta (cinco dimensiones, escala 1–5) en `06_Experimento/instrumentos/`.
4. Hoja de evaluacion a ciegas (`06_Experimento/instrumentos/hoja_evaluacion_a_ciegas.csv`).
5. Plantilla de consentimiento actualizado (carpeta `08_Etica/`).

3.7. Plan de analisis estadistico

1. Normalidad de las diferencias apareadas: prueba de Shapiro-Wilk.
2. Comparacion de medias: t pareada (normales) o Wilcoxon (no normales).
3. Tamano del efecto: d de Cohen o delta de Cliff.
4. Correccion por comparaciones multiples (Bonferroni).
5. Acuerdo inter-evaluador: kappa de Cohen por pares y kappa de Fleiss.
6. Potencia estadistica previa: alpha 0.05, 1-beta 0.80 [?].

Todos los calculos se ejecutan con los scripts versionados en `06_Experimento/scripts_analisis/analisis_ef1` a partir de los datos crudos de `06_Experimento/resultados/`.

Referencias